

# Taller No.5 Detector Haars y Support Vector Machine

Niño Rivera María Carolina, Arias Buitrago Cristian Camilo, Machado Manuel  
{*maria.nino02*}@usa.edu.co, {*cristian.arias02*}@usa.edu.co, {*manuel.machado01*}@usa.edu.co  
Profesor: Rudas Jorge

**Resumen**—Las técnicas de detección de rostros ayudan a encontrar los datos más importantes que presenta un rostro, en este taller se utilizaron técnicas de Haar para la identificación de las principales características, además para encontrar los mejores valores se utilizaron técnicas de PCA también conocidos como Eigenfaces. Ésta técnica lleva la comparación a través de las características extraídas por medio de los atributos de definidos. También se emplearon técnicas de clasificación por medio del método de Support Vector Machine.

**Palabras clave**—Detección de rostros, clasificación, Haar, SVM.

## I. INTRODUCCIÓN

La detección de rostros es un técnica basada en características que intentan encontrar las ubicaciones distintivas de la imagen como los ojos, la nariz y la boca y luego se verifica si estas características se encuentran en una disposición geométrica plausible [1]. Existen varios enfoques o técnicas para realizar esta identificación como son:

- Enfoque basado en plantillas: En la que pueden manejar una amplia gama de variaciones de poses y expresiones, pero no son adecuados como detectores rápidos de rostros debido a que requieren una buena inicialización de un rostro real [1].
- Clustering y PCA: Figuración de patrones faciales y no faciales, el resultado se ingresa en un perceptron multicapa, es decir red neuronal completamente conectada [1].
- Neural Network: En lugar de agrupar se aplica una red neuronal Multi Layer Perceptron (MLP), esta red se suele entrenar por medio de un algoritmo de retropropagación de errores o BP (Back Propagation) de ahí que dicha arquitectura se conozca también bajo el nombre de red de retropropagación [2]. Se utiliza esta red en particular en los parches de nivel de gris [1].
- Support Vector Machine: Procesar los parches, este método busca una serie de planos de separación de margen máximo en el espacio de características entre las diferentes clases [1].
- Boosting: Se entrenan una serie de clasificadores simples cada vez más discriminativos y luego se combinan los resultados [1].

El presente documento corresponde a un informe de práctica de laboratorio de Inteligencia Artificial presentado en la Universidad Sergio Arboleda durante el periodo 2022-2.

La detección de objetos mediante clasificadores en cascada basados en funciones de Haar es un método eficaz de detección de objetos propuesto por Paul Viola y Michael Jones en su artículo, “Detección rápida de objetos mediante una cascada potenciada de funciones simples” en 2001. Es un enfoque basado en el aprendizaje automático en el que un La función de cascada se entrena a partir de muchas imágenes positivas y negativas. Luego se usa para detectar objetos en otras imágenes [3]. La detección de rostros se suele utilizar para:

- Interacción humanos y computadoras.
- Verificación de identidad.
- Inicio de sesión.
- Controles parentales.
- Monitoreo de pacientes.

## II. HAARS

Este método realiza el proceso de detección de objetos a partir de imágenes utilizando características o estructuras específicas del objeto en cuestión. Sin embargo, había un problema. Trabajar solo con intensidades de imagen, es decir, los valores de píxeles RGB en cada píxel de la imagen, hizo que el cálculo de características fuera bastante costoso desde el punto de vista computacional y, por lo tanto, lento en la mayoría de las plataformas. Este problema fue abordado por las denominadas características tipo Haar, desarrolladas por Viola y Jones sobre la base de la propuesta de Papageorgiou et. al en 1998. Una función similar a Haar considera regiones rectangulares vecinas en una ubicación específica en una ventana de detección, suma las intensidades de píxeles en cada región y calcula la diferencia entre estas sumas. Esta diferencia es luego se usa para categorizar subsecciones de una imagen. Un ejemplo de esto sería la detección de rostros humanos. Comúnmente, las áreas alrededor de los ojos son más oscuras que las áreas de las mejillas. Por lo tanto, un ejemplo de una característica similar a Haar para la detección de rostros es un conjunto de dos áreas rectangulares vecinas sobre las regiones de los ojos y las mejillas. [4].

En 2001, Paula Viola y Michael Jones propusieron un nombre de artículo “Rapid Object Detection using a Boosting Cascade of Simple Features” o en español “Detección rápida de objetos usando una cascada de refuerzo de características simples”. La cascada de Haar es un conjunto de características similares a las de Haar que se combinan para formar un clasificador. La característica es el valor de píxel en la escritura

restado del valor de píxeles en el área en blanco. La base del detector de rostros es de 24 x 24. A partir de ese detector de rostros base, hay alrededor de 160k de características similares a las de Haar. Sin embargo, no todas estas características se utilizan [7].

### III. CASCADA DE CLASIFICADORES

La técnica cascada se basa en la concatenación de varios clasificadores débiles, cada uno analizando una porción diferente de una imagen o frame en el caso de vídeo. Se consideran débiles porque tienen alta probabilidad de dar falso positivo, pero cuando se combinan los resultados, en conjunto, por el contrario, son muy potentes [5]. El objeto de clasificación organiza la imagen según el valor de las características, que refiere al rectángulo o bloque de píxeles encontrados en una ventana de detección cerrada. En este sentido, manifiestan que existen muchas motivaciones para usar características en vez de píxeles directamente en función de la intensidad [5].

El objetivo principal de la utilización de los clasificadores en cascada viene de observar que el número de caras que se encuentran en una imagen es limitado, sin embargo el detector se evalúa utilizando el método de ventana deslizante, generando un número elevado de hipótesis que van a corresponder a desplazar la ventana por toda la imagen a múltiples escalas. En donde la gran mayoría de ventanas que se formulan como hipótesis en realidad no corresponden a una cara. Con base a esto el objetivo principal es descartar el mayor número posible de ventanas que no contienen una cara con el mínimo esfuerzo, para poder concentrar un mayor esfuerzo computacional en aquellas ventanas que realmente tienen una mayor probabilidad de ser una cara [6].

La cascada de clasificadores permite alcanzar este objetivo mediante una combinación secuencial de clasificadores, de forma que una imagen solo será detectada como cara si es realmente reconocida de forma correcta como cara por todos los clasificadores de la cascada, si uno de los clasificadores la rechaza, la imagen quedará rechazada. Así el primer clasificador va a recibir todas las posibles ventanas de una imagen. Todas aquellas que rechaza este primer clasificador quedarán descartadas. Las que el clasificador acepta, se pasarán al segundo clasificador. Este proceso se repite hasta llegar al último clasificador. Solo las imágenes que sean reconocidas como cara por este último clasificador y que por lo tanto también han sido reconocidas por los clasificadores anteriores van a ser la detección final de caras que va a producir el detector [6].

La reducción de tiempo se obtiene de dos características, la primera, el número de imágenes que se va procesando a medida que se avanza por la cascada se va reduciendo. La segunda, el número de características que se van a utilizar en los primeros clasificadores va a ser muy bajo, con lo que se puede descartar muchas imágenes de forma rápida [6].

El algoritmo utiliza ventanas del mismo tamaño con 2, 3 y 4 rectángulos también con igual dimensión. En cada una de esas ventanas aplica la función Haar que se calcula como la suma de los píxeles que se encuentran dentro de los rectángulos

blancos y se resta con la suma de los píxeles del rectángulo sombreado [5]. En la figura 1 se observa la imagen de entrada planteada por Viola y Jones.




Figura 1. Características de entrada definida por Viola y Jones

### IV. APLICACIONES DE LAS CASCADAS DE HAAR

Esta metodología puede aplicarse a diferentes campos, entre las que se cuentan en la siguiente lista [8]:

1. Reconocimiento facial : Similar a cómo el iPhone X usa el reconocimiento facial, otros dispositivos electrónicos y protocolos de seguridad pueden usar las cascadas de Haar para determinar la validez del usuario para un inicio de sesión seguro.
2. Robótica: Las máquinas robóticas pueden “ver” su entorno para realizar tareas mediante el reconocimiento de objetos. Por ejemplo, esto se puede utilizar para automatizar tareas de fabricación.
3. Vehículos autónomos: Los vehículos autónomos requieren conocimiento sobre su entorno, y las cascadas de Haar pueden ayudar a identificar objetos, como peatones, semáforos y aceras, para producir decisiones más informadas y aumentar la seguridad.
4. Búsqueda de imágenes y reconocimiento de objetos: Ampliando el reconocimiento facial, se puede buscar cualquier variedad de objetos mediante el uso de un algoritmo de visión por computadora, como las cascadas de Haar.
5. Agricultura: Los clasificadores de Haar se pueden usar para determinar si los insectos dañinos están volando sobre las plantas, lo que reduce la escasez de alimentos causada por las plagas.
6. Uso industrial: Los clasificadores de Haar se pueden usar para permitir que las máquinas recojan y reconozcan ciertos objetos, automatizando muchas de las tareas que antes solo podían hacer los humanos.

### V. DESCRIPTORES

Un descriptor es una herramienta de procesamiento de imágenes cuya función principal es la de extraer información y características de una imagen, motivo por el cual también es llamado vector de características. Los descriptores tienen además un papel muy importante en el reconocimiento de patrones, ya que son ellos los que se encargan de extraer características locales, de manera independiente, al patrón de referencia y a la región de la imagen para posteriormente realizar una correspondencia [9].

Para que un descriptor presente un buen diseño debe de responder a las siguientes características [9], [10]:

- Robustez frente a las posibles variaciones de apariencia de los objetos.
- Suficientemente discriminativo para poder distinguir en una imagen los patrones de referencia almacenados.
- Invariante a la orientación de los diferentes objetos.
- Insensible a pequeñas imprecisiones al localizar objetos en una imagen.
- Exactitud, la localización de características debe llevarse a cabo de forma precisa, principalmente en tareas de emparejamiento.
- Repetibilidad, debe ser capaz de repetir las detecciones de características de los mismos objetos o escenas bajo diferentes condiciones de visualización.
- Eficiencia, debe realizar las detecciones de forma rápida, de tal manera que pueda ser empleado en aplicaciones en tiempo real.
- Alta densidad, la cantidad o densidad de las características detectadas debe corresponder a la información contenida en la imagen.

Todos estos factores pueden ser implementados por diferentes características que definan el descriptor. Por este motivo, no existe un descriptor universal ya que, en función de cual sea el objetivo del procesamiento de una determinada imagen, responderán mejor unos u otros [9].

## VI. TIPOS DE DETECTORES

Estos detectores, pueden ser clasificados en tres categorías; detectores a una escala, detectores multi-escala y detectores afines invariantes. Los primeros son detectores que son invariantes a transformaciones de la imagen, es decir, pueden detectar las características del objeto ante cambios tales como desplazamiento, rotación y cambios de iluminación, sin embargo, no funcionan ante cambios de escala. Los detectores multi-escala tienen la capacidad de lidiar con los problemas de escalamiento, a diferencia de los primeros. Por último, los detectores afines invariantes pueden trabajar incluso con imágenes tomadas desde diferentes perspectivas visuales [10].

## VII. SUPPORT VECTOR MACHINE SVM

La máquina de vectores de soporte (SVM) fue propuesta por primera vez por Vapnik y desde entonces ha atraído un alto grado de interés en la comunidad de investigación de aprendizaje automático [11]. Los SVM son un conjunto de métodos de aprendizaje supervisado relacionados que se utilizan para la clasificación y la regresión, pertenecen a una familia de clasificación lineal generalizada. Una propiedad especial de este método es que minimiza simultáneamente el error de clasificación empírica y maximiza el margen geométrico. Debido a esto se llamó Clasificadores de Máximo Margen. Se basa en la Minimización del riesgo estructural (SRM) [11].

El método SVM se construye sobre la base de un número limitado de muestras en la información contenida en el texto de capacitación existente para obtener los mejores resultados

de clasificación. En los últimos años, el enfoque de investigación de muchos académicos se ha convertido en problemas prácticos de fundamento teórico riguroso, pero también resuelven mejor los puntos mínimos locales, no lineales, de alta dimensión y de pequeña muestra [12].

La máquina de vectores de soporte es una descripción bidimensional de la superficie óptima desarrollada a partir del caso separable linealmente. Dos tipos están separados por H sin errores. H1 H2 son lugares que pasan por el punto reciente de H. La distancia de H1 y H2 se denominó intervalo de clase. La superficie de separación óptima no es solo para garantizar la separación sin errores de los dos tipos de muestras, también llamado el intervalo de clase más grande. Esta descripción se puede visualizar en la imagen 2




Figura 2. Superficie de separación óptima

Ventajas y desventajas de SVM [13]. Las principales ventajas son:

- Funciona muy bien con un claro margen de separación.
- Es eficaz en espacios de gran dimensión.
- Es eficaz en los casos en que el número de dimensiones es mayor que el número de muestras.
- Utiliza un subconjunto del conjunto de entrenamiento en la función de decisión (llamados vectores de soporte), por lo que también es eficiente en memoria.

Las principales desventajas son:

- No funciona bien cuando se tiene un gran conjunto de datos porque el tiempo de entrenamiento requerido es mayor.
- Tampoco funciona muy bien cuando el conjunto de datos tiene más ruido, es decir, las clases objetivo se superponen.
- SVM no proporciona directamente estimaciones de probabilidad; estos se calculan utilizando una costosa validación cruzada de cinco veces.

## VIII. APLICACIONES DE SVM

Las máquinas de vectores de soporte se utilizan ampliamente en varios campos, como el reconocimiento facial, la clasificación de imágenes, el reconocimiento de notas y el reconocimiento de voz, en el reconocimiento de patrones y en muchos campos de análisis de datos, como la detección de virus, el filtrado de spam y la detección de intrusos en la red [14].

- Reconocimiento facial. La idea central del reconocimiento facial es utilizar conocimientos o métodos estadísticos para modelar el rostro. Es más probable que el área

a inspeccionar coincide con el modelo de la cara en un fondo complejo y juzgue si existe una cara y se separa. En la actualidad, la tecnología de detección de reconocimiento facial es relativamente madura y se aplica a varios campos. Osuna propuso por primera vez utilizar el método SVM en la tecnología de reconocimiento facial entrenando un clasificador SVM no lineal para detectar y clasificar rostros y no rostros. Se propuso un análisis básico de componentes principales (PCA). El marco de mejora del reconocimiento facial +LDA + SVM, que utiliza el algoritmo de optimización de enjambre de partículas para optimizar los dos parámetros importantes de penalización por acomodación y las funciones del kernel de SVM para obtener la solución óptima, se usa para entrenar al clasificador final para el reconocimiento facial y obtener una precisión de reconocimiento más alta.

- Clasificación de imágenes. Las imágenes se han convertido en un importante medio de transmisión y obtención de información en la vida y el trabajo de las personas. El posicionamiento rápido de las imágenes y la clasificación adecuada de las imágenes son muy importantes para mejorar la precisión de la recuperación de imágenes basada en el contenido. La literatura propone métodos de clasificación de imágenes simples e imágenes complejas basados en SVM. La literatura combina efectivamente la idea del aprendizaje semisupervisado con máquinas de vectores de soporte y propone un método de clasificación de gráficos pequeños para etiquetar SVM semisupervisado medio, basado en el cambio medio. El método del valor del parámetro del algoritmo se mejora con el resultado del cambio medio para que el resultado de la clasificación de imágenes pueda obtener una mayor precisión de clasificación y eficiencia de tiempo.
- Detección de intrusiones en la red. La tecnología de detección de intrusos recopila y analiza información sobre nodos clave en los sistemas de redes informáticas y responde a las violaciones de las políticas de seguridad de manera oportuna. Los datos en la detección de intrusos en la red son muy grandes y complejos. Tiene las características de grandes dimensiones, muestras pequeñas e inseparabilidad lineal. SVM, como método desarrollado sobre la base del aprendizaje automático de muestras pequeñas, utiliza el principio de minimización de riesgos para resolver problemas como muestras pequeñas, no linealidad y dimensiones altas, pero es capaz de mantener un alto nivel de falta de conocimiento previo. La precisión de la clasificación es muy adecuada para los sistemas de detección de intrusos en la red.

## IX. TALLER DETECCIÓN DE ROSTROS FEMENINOS Y MASCULINOS

### IX-A. Conjunto de datos

Para la realización de este taller se utilizó las imágenes libres descargadas de Kaggle [15] el cual es un conjunto de rostros de hombres y mujeres compuesto por 5418 imágenes

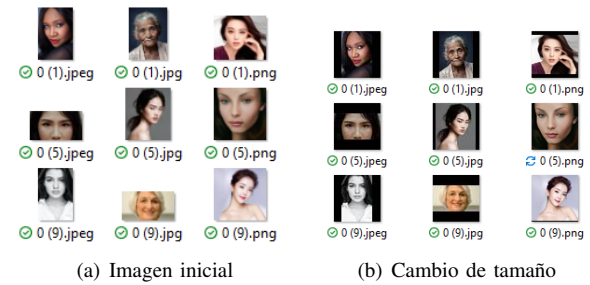


Figura 3. Resultados proceso de cambio del conjunto de datos

en formatos “jpeg”, “jpg” y “png”, se encontraron varias imágenes repetidas, además las dimensiones de las imágenes encontradas son diferentes. Con un total de 2698 rostros de mujeres y 2720 en el conjunto de los hombres. Este grupo de fotos cubren múltiples etnias y grupos de edad (12-13 % de los datos pertenecen a personas mayores en ambos conjuntos de datos). Debido a que para encontrar las características en imágenes muy grandes requeriría demasiado tiempo se realizó una etapa de preprocesamiento, en el cual no solo se redimensionaban las imágenes a tamaños de 50\*50 y 25\*25 píxeles sino que además se hizo un función que evaluaba el radio para que el resultado fuera una imagen más cuadrada y de esta manera estandarizar el conjunto de imágenes a utilizarse. El proceso tomo cerca a los cuatro minutos en completarse, los resultados de algunas imágenes puede verse en la figura 3. Se puede apreciar como caras donde solo se muestra una parte se centraron un poco más además se observa como el conjunto ahora esta con formas mas parejas.

### IX-B. Clasificación de Rostros

Para la clasificación del rostro se utilizó la extracción de características de Haar y el algoritmo de clasificación SVM. Los pasos realizados para esta clasificación son los siguientes:

1. Lectura de las imágenes redimensionadas, transformando las en un arreglo, previamente se transformaron en escala de grises para que la identificación de las características fuera mucho más fácil.
2. Recorrer cada imagen del conjunto redimensionado para extraer las características, para esto se construyó una función que recibía por parámetro la imagen, los tipos de características a buscar y un parámetro vacío de coordenadas. Dentro de esta función se utilizó el método de Scikit llamado “haar\_like\_feature”. Para poder utilizarla es importante hacer una transformación a la imagen en formato integral. Después de eso, se selecciona una pequeña cantidad de características críticas de este gran conjunto de características potenciales (por ejemplo, usando el algoritmo de aprendizaje AdaBoost [16].
3. Para cada uno de estas características se adicionaban en una lista final de descriptores, de la misma manera se generaba una lista con las etiquetas que indicaban si se trata de una imagen femenina o masculina.



4. Clasificación SVM. Esta función creada recibía como parámetro las etiquetas y la lista de todas las características seleccionadas. El primer paso a trabajar era dividir el conjunto de datos en entrenamiento y prueba en un porcentaje de 75 % y 25 % respectivamente, utilizando un estado aleatorio de 42. Posteriormente se utilizó el método “StandardScaler” ya que permite estandarizar las características eliminando la media y escalando a la varianza de la unidad. La estandarización de un conjunto de datos es un requisito común para muchos estimadores de aprendizaje automático: es posible que se comporten mal si las características individuales no se parecen más o menos a los datos estándar distribuidos normalmente (p. ej., gaussiana con media 0 y varianza unitaria) [17]. Se utilizó PCA para tomar los componentes más importantes de las caras y pasarlos a la función SVC (Support Vector Classification) del método SVM. La implementación se basa en libsvm. El tiempo de ajuste escala al menos cuadráticamente con el número de muestras y puede no ser práctico más allá de decenas de miles de muestras [18].

## X. RESULTADOS

El proceso final permitió la clasificación de rostro de hombres y mujeres, al realizar el proceso con el cambio de 50\*50 y 25\*25 el resultado fue muy similar pero la respuesta en tiempo fue muy diferente. Las características elegidas incluían el ancho de las cejas, la separación de los ojos, el ancho de la nariz, el largo de la nariz, la separación entre el labio y la nariz y el tamaño de la mandíbula. En la figura 4 se pueden observar los resultados en la matriz de confusión, esta es una herramienta que permite visualizar el desempeño de un algoritmo de aprendizaje supervisado. Cada columna de la matriz representa el número de predicciones de cada clase, mientras que cada fila representa a las instancias en la clase real.

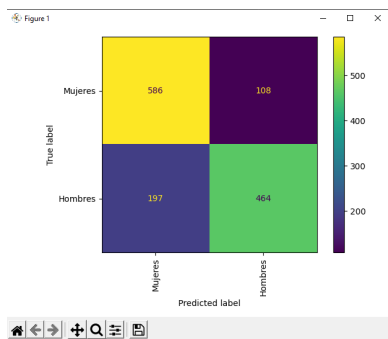


Figura 4. Matriz de confusión resultados

La matriz de confusión y las métricas están basadas en cuatro regiones [19]:

1. Verdadero positivo: El valor real es positivo y la prueba predijo también que era positivo. O bien una persona es mujer y la prueba así lo demuestra.

Resultados métricas de desempeño				
Mujeres	Precisión 0.75	Recall 0.84	F1-Score 0.79	Support 694
Hombres	0.81	0.70	0.75	661
Accuracy			0.77	1355
Macro avg	0.78	0.77	0.77	1355
Weighted avg	0.78	0.77	0.77	1355

Tabla I  
MÉTRICAS DE DESEMPEÑO

- Verdadero negativo: El valor real es negativo y la prueba predijo también que el resultado era negativo. O bien la persona es hombre y la prueba así lo demuestra.
- Falso negativo: El valor real es positivo, y la prueba predijo que el resultado es negativo. La persona es mujer, pero la prueba dice de manera incorrecta que es hombre. Esto es lo que en estadística se conoce como error tipo II.
- Falso positivo: El valor real es negativo, y la prueba predijo que el resultado es positivo. La persona es hombre, pero la prueba nos dice de manera incorrecta que es mujer.

Para los resultados obtenidos se puede validar que en el caso de las mujeres se presentaron 108 casos como mujeres cuando en realidad eran hombres y para el caso de los hombres se presentaron 197 casos como hombre cuando en realidad eran mujeres. Para poder entender mejor estos resultados se ha utilizado las métricas de desempeño, cuyos valores pueden visualizarse en la tabla I.

## XI. CONCLUSIONES

A pesar que se redujeron las imágenes a resoluciones muy pequeñas el algoritmo y las funciones utilizadas fueron capaces de reconocer las características más importantes que permiten la diferenciación entre mujeres y hombres, además el algoritmo de Haar permite la extracción de manera ordenada de las principales características. Sin embargo se puede observar que se presentan un porcentaje de error grande en especial en el caso de las mujeres donde la precisión fue sólo del 75 %. Para obtener mejores resultados es importante realizar un preprocesamiento de imágenes con el fin de estandarizar los formatos y centrar mejor el rostro de las personas. Muchas de las imágenes se encontraban repetidas y en algunos casos solo se tenían partes parciales del rostro o se encontraban en posiciones de perfil.

## REFERENCIAS

- Computer Vision: Algorithms and Applications 2nd Edition. **Richard Szeliski**. September 30, 2021.
- Tema 8. Redes Neuronales <http://www.sc.edu/es/ccwbayes/docencia/mmcc/docs/t8neuronales.pdf>. Recuperado el 14 de Octubre de 2022.
- Clasificador en cascada OpenCV [https://docs.opencv.org/4.x/db/d28/tutorial\\_cascade\\_classifier.html](https://docs.opencv.org/4.x/db/d28/tutorial_cascade_classifier.html). Recuperado el 14 de Octubre de 2022.
- Object detection using Haar-cascade Classifier *Soo, Sander* Institute of Computer Science, University of Tartu [https://www.academia.edu/38877608/Object\\_detection\\_using\\_Haar\\_cascade\\_Classifier](https://www.academia.edu/38877608/Object_detection_using_Haar_cascade_Classifier). Recuperado el 04 de Marzo de 2023.

- [5] Reconocimiento de objetos a través de la metodología Haar Cascades *Ezequiel Ángel Jeremías Ambrogio* <https://confedi.org.ar/wp-content/uploads/2020/12/Articulo1-RADI16.pdf>. Recuperado el 14 de Octubre de 2022.
- [6] 5.5. Cascada de clasificadores Coursera <https://es.coursera.org/lecture/deteccion-objetos/5-5-cascada-de- clasificadores-pRnHu>. Recuperado el 14 de Octubre de 2022.
- [7] Facial Emotion Detection Using Haar-Cascade Classifier and Convolutional Neural Networks *P A Riyantoko*, 2021 <https://iopscience.iop.org/article/10.1088/1742-6596/1844/1/012004/pdf>. Recuperado el 04 de Marzo de 2023.
- [8] Haar Cascades, Explained *Mittal, Aditya*, 2020/12/20 <https://medium.com/analytics-vidhya/haar-cascades-explained-38210e57970d>. Recuperado el 04 de Marzo de 2023.
- [9] Seguimiento de Patrones Faciales por Descriptores de Forma *Leyva, Enric Vals*, 2008/07/04 <http://www.maia.ub.es/~sergio/linked/quique08.pdf>. Recuperado el 04 de Marzo de 2023.
- [10] Detección efectiva de rostros en imágenes utilizando descriptores basados en HOG Effective Face Detection on Images by Using Descriptors Based on HOG *Alcántara-Montiel, Cinthia and Pedraza Ortega, Jesus Carlos and Ramos-Arreguin, Juan-Manuel and Gorrostieta-Hurtado, Efrén and Tovar-Arriaga, Saúl and Vargas-Soto, J*, 2019 <http://www.maia.ub.es/~sergio/linked/quique08.pdf>. Recuperado el 04 de Marzo de 2023.
- [11] Data classification using support vector machine *Srivastava, Durgesh; Bhambhu, Lekha* 2010 [https://www.researchgate.net/publication/285663733\\_Data\\_classification\\_using\\_support\\_vector\\_machine](https://www.researchgate.net/publication/285663733_Data_classification_using_support_vector_machine). Recuperado el 04 de Marzo de 2023.
- [12] Support Vector Machine Classification Algorithm and Its Application *Zhang, Yongli* 2012 [https://link.springer.com/chapter/10.1007/978-3-642-34041-3\\_27#citeas](https://link.springer.com/chapter/10.1007/978-3-642-34041-3_27#citeas). Recuperado el 04 de Marzo de 2023.
- [13] Learn How to Use Support Vector Machines (SVM) for Data Science *Sunil, Ray* 2017/09/13 <https://www.analyticsvidhya.com/blog/2017/09/understaing-support-vector-machine-example-code/>. Recuperado el 04 de Marzo de 2023.
- [14] Improvement of Support Vector Machine Algorithm in Big Data Background *Gaye, Babacar and Zhang, Dezheng and Wulamu, Aziguli* 2021/06/17 <https://www.hindawi.com/journals/mpe/2021/5594899/>. Recuperado el 04 de Marzo de 2023.
- [15] Male and female faces dataset *Kaggle*, 2021 <https://www.kaggle.com/datasets/ashwingupta3012/male-and-female-faces-dataset?resource=download>. Recuperado el 04 de Marzo de 2023.
- [16] Haar-like feature descriptor *Scikit*, 2023 [https://scikit-image.org/docs/stable/auto\\_examples/features\\_detection/plot\\_haar.html](https://scikit-image.org/docs/stable/auto_examples/features_detection/plot_haar.html). Recuperado el 04 de Marzo de 2023.
- [17] sklearn.preprocessing.StandardScaler *ScikitLearn*, 2023 <https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html>. Recuperado el 04 de Marzo de 2023.
- [18] sklearn.svm.SVC *ScikitLearn*, 2023 <https://scikit-learn.org/stable/modules/generated/sklearn.svm.SVC.html>. Recuperado el 04 de Marzo de 2023.
- [19] La matriz de confusión y sus métricas *BigData*, 2019/07/26 <https://www.juanbarrios.com/la-matriz-de-confusion-y-sus-metricas/>. Recuperado el 04 de Marzo de 2023.